

LAS 10 ETAPAS DE LA METODOLOGÍA DS

Un proceso iterativo y estructurado para resolver problemas de negocio con datos. Cada etapa responde una pregunta clave y alimenta a la siguiente. Incluye ejemplos del caso hospital y manufactura.

10
ETAPAS CLAVE

70-90%

del tiempo de un proyecto se va en preparación de datos

50%

reducción de tiempo al automatizar el proceso de datos

CRISP-DM

metodología estándar más usada en la industria

5

tipos de enfoque analítico según el tipo de pregunta

CASO DE ESTUDIO QUE USAREMOS EN TODAS LAS ETAPAS

Hospital: Predicción de Readmisión por Insuficiencia Cardíaca

Un proveedor de seguros de salud necesita asignar un presupuesto limitado para maximizar la calidad de atención. El objetivo es predecir qué pacientes con insuficiencia cardíaca serán readmitidos al hospital, para intervenir antes de que eso ocurra.

PROBLEMA DE NEGOCIO

Reducir readmisiones hospitalarias innecesarias y costosas. Cada readmisión implica costo médico alto y riesgo para el paciente.

ENFOQUE ELEGIDO

Modelo de clasificación con árbol de decisión. Responde: "¿Este paciente SÍ o NO se readmitirá?" con probabilidad asociada.

POR QUÉ ÁRBOL DE DECISIÓN

Es accesible para clínicos sin formación matemática. Muestra reglas claras: "si edad > 70 y no tomó medicamento → riesgo alto".

Las 10 Etapas — Definición, Ejemplo y Analogía

ETAPA 01 — COMPRENSIÓN DEL NEGOCIO

Business Understanding

1

"¿Cuál es el problema que estás tratando de resolver?"

¿QUÉ ES?

La primera etapa. Antes de tocar datos, debes entender exactamente qué pregunta quieres responder. Implica reuniones estructuradas con los interesados del negocio para identificar objetivos y prioridades. Sin claridad aquí, todo lo demás falla.

EJEMPLO · HOSPITAL

El seguro pregunta: "¿Cómo maximizar calidad de atención con presupuesto limitado?" El científico de datos reformula: "¿Podemos predecir qué pacientes con insuficiencia cardíaca serán readmitidos dentro de 30 días?"

ANALOGÍA

Es como cuando el doctor te pregunta "¿dónde te duele?" antes de ordenar cualquier análisis. Sin esa pregunta inicial bien hecha, los exámenes serían al azar y el diagnóstico fallará.

ETAPA 02 — ENFOQUE ANALÍTICO

Analytic Approach

2

"¿Cómo puedes usar los datos para responder la pregunta?"

¿QUÉ ES?

Según el tipo de pregunta, se elige el tipo de análisis: descriptivo, diagnóstico, predictivo, prescriptivo o clasificación. Esta elección define qué algoritmos y técnicas se usarán en todo el proyecto.

EJEMPLO · HOSPITAL

La pregunta es "¿SÍ o NO se readmite?" → es una pregunta de clasificación binaria → se elige árbol de decisión. El modelo aprende de historiales de pacientes y aplica las reglas a nuevos casos.

ANALOGÍA

Como elegir la herramienta antes de construir: si necesitas cortar madera usas sierra, no martillo. El tipo de pregunta determina la herramienta (algoritmo) correcta.

ETAPA 03 — REQUISITOS DE DATOS

Data Requirements

3

"¿Qué datos necesitas para responder la pregunta?"

¿QUÉ ES?

Define qué información es necesaria, en qué formato y de qué fuentes. Incluye los criterios de inclusión del grupo de estudio. La anticipación de las etapas posteriores es clave para no volver atrás por datos faltantes.

EJEMPLO · HOSPITAL

Se necesitan: historial clínico completo, diagnósticos primarios/secundarios, medicamentos, edad, género, número de ingresos previos. El grupo: pacientes con diagnóstico principal de insuficiencia cardíaca congestiva.

ANALOGÍA

Como hacer la lista del supermercado antes de ir. Si no sabes qué ingredientes necesitas para la receta, vas a comprar de más, de menos, o te faltará algo crítico al momento de cocinar.

ETAPA 04 — RECOLECCIÓN DE DATOS

Data Collection

4

"¿De dónde proviene la fuente y cómo recibirás los datos?"

¿QUÉ ES?

Se obtienen los datos de las fuentes identificadas. Los DBAs (administradores de bases de datos) y programadores extraen y fusionan fuentes, eliminando redundancias. Algunas brechas se identifican y se planifican estrategias para llenarlas.

EJEMPLO · HOSPITAL

Se extraen datos demográficos, registros de reclamaciones, resultados de laboratorio y medicamentos de distintas bases. Si un dato no está disponible (ej: tipo de dieta), se pospone y se adquiere después si es relevante.

ANALOGÍA · MAQUILA

Es como recopilar registros de producción de distintas líneas: hojas de operario, reportes de calidad, tiempos de máquina. Cada fuente está separada y hay que unirlos sin duplicar registros.

ETAPA 05 — COMPRENSIÓN DE DATOS

Data Understanding

5

"¿Los datos que recopilaste representan el problema a resolver?"

¿QUÉ ES?

Se analizan los datos con estadísticas descriptivas (media, mediana, mín, máx, desviación estándar), correlaciones entre variables e histogramas. El objetivo es detectar anomalías, redundancias y entender la distribución de los datos antes de modelar.

EJEMPLO · HOSPITAL

Al revisar el campo "edad" se encuentra un valor de 999 — que en realidad significa "desconocido". Los histogramas revelan que hay más pacientes jóvenes de lo esperado, indicando que la definición de insuficiencia cardíaca era demasiado amplia.

ANALOGÍA

Como revisar los ingredientes antes de cocinar: verificas que la leche no esté caducada, que el azúcar no sea sal, y que las cantidades sean las correctas. Ahorras desastres al final.

Data Preparation

"¿Qué trabajo adicional se requiere para trabajar con los datos?"

¿QUÉ ES?

La etapa más larga: limpieza, transformación, ingeniería de características (feature engineering) y análisis de texto si aplica. Consume entre 70-90% del tiempo total del proyecto. Automatizar reduce este porcentaje al 50%.

EJEMPLO · HOSPITAL

Se recodifica "edad 999" como valor nulo. Se agrupan los registros transaccionales al nivel de paciente. Se crea la variable "número de hospitalizaciones previas en 12 meses" combinando múltiples registros individuales.

ANALOGÍA

Es como lavar, pelar y cortar las verduras antes de cocinar. No importa qué tan buena sea tu receta — si los ingredientes están sucios o mal cortados, el platillo saldrá mal de todas formas.

ETAPA 07 — MODELADO

7

Modeling

"¿Al aplicar visualizaciones, ves respuestas que abordan el problema?"

¿QUÉ ES?

Se construye el modelo usando el conjunto de entrenamiento (datos históricos con resultados conocidos). Se prueban diferentes algoritmos y se ajustan parámetros. Existen dos tipos: modelos descriptivos (patrones) y predictivos (probabilidades).

EJEMPLO · HOSPITAL

Modelo 1 (costo 1:1): precisión 85% general, pero solo detecta 45% de las readmisiones reales. Demasiados pacientes de riesgo se van a casa sin intervención. Se necesita ajustar el costo relativo.

ANALOGÍA

Como probar la salsa mientras cocinas y decidir si necesita más condimentos. El conjunto de entrenamiento es tu historial de recetas anteriores que ya sabes cómo salieron.

ETAPA 08 — EVALUACIÓN

8

Evaluation

"¿El modelo responde la pregunta inicial o necesitas ajustar?"

¿QUÉ ES?

Se mide el desempeño con métricas clave: precisión general, sensibilidad (verdaderos positivos), especificidad (verdaderos negativos), curva ROC y AUC. Se elige el modelo con mejor balance según el negocio, no el más preciso en general.

EJEMPLO · HOSPITAL

Modelo 3 (costo 4:1): 68% sensibilidad, 15% falsos positivos, 81% precisión. Gana porque tiene la mayor separación en la curva ROC ($0.68 - 0.15 = 0.53$) y es defendible ante el equipo médico y directivo.

ANALOGÍA

Como calificar un examen con rúbrica. No basta con el puntaje total — importa qué tipo de errores cometió el alumno y cuáles son más graves en ese contexto específico.

ETAPA 09 — DESPLIEGUE

9

Deployment

"¿Puedes poner el modelo en práctica?"

¿QUÉ ES?

El modelo se integra en sistemas reales para que usuarios finales lo usen sin saber que hay un algoritmo detrás. Puede ser un dashboard, una alerta automática, una recomendación en pantalla, o un reporte periódico.

EJEMPLO · HOSPITAL

El árbol de decisión queda disponible en el sistema clínico. Cuando un médico ingresa los datos de un paciente, el sistema muestra automáticamente: "Riesgo

ANALOGÍA · MAQUILA

Es como instalar un semáforo en la línea de producción que se pone en rojo automáticamente cuando los datos del turno predicen una

de readmisión: ALTO – 78%" y sugiere seguimiento intensivo.

falla en los próximos 2 horas. El operario actúa, no el algoritmo.

ETAPA 10 — RETROALIMENTACIÓN

Feedback

10

"¿Puedes obtener retroalimentación constructiva para responder mejor?"

¿QUÉ ES?

La metodología es iterativa, no lineal. Los resultados del mundo real retroalimentan el modelo: nuevos datos, nuevas variables, cambios en el negocio. Se pueden volver a etapas anteriores en cualquier momento para mejorar.


EJEMPLO · HOSPITAL

Los médicos reportan que el modelo no identifica bien a pacientes con diabetes. Se vuelve a la etapa 3 para incluir variables de hemoglobina glicosilada. El modelo mejora su precisión en ese subgrupo un 12%.

ANALOGÍA

Como mejorar una receta con cada vez que la cocinas. Después de cada vez que alguien la prueba, ajustas la sal, el tiempo de cocción o los ingredientes. El modelo nunca está "terminado" — siempre se puede mejorar.

El proceso NO es lineal — es iterativo



En cualquier etapa puedes descubrir que necesitas volver atrás. Por ejemplo: al comprender los datos (etapa 5) puedes darte cuenta de que necesitas más datos (etapa 4), o que el problema estaba mal definido (etapa 1). Esto es normal y esperado.

Los 5 Tipos de Enfoque Analítico

Descriptivo

"¿Cuál es la situación actual?"

Técnicas: agregación de datos, minería de datos, visualización, dashboards.

Ej: resumen de producción diaria por línea, reportes de defectos por turno en maquila.

Diagnóstico

"¿Por qué ocurrió esto?"

Técnicas: análisis de correlaciones, desglose de datos, descubrimiento de patrones.

Ej: ¿Por qué bajaron las ventas en marzo? ¿Por qué aumentaron los defectos en la línea 3?

Predictivo

"¿Qué es probable que ocurra?"

Técnicas: regresión, series de tiempo, modelos de Machine Learning.

Ej: forecast de demanda para la próxima semana, predicción de readmisión de pacientes.

Prescriptivo

"¿Qué debemos hacer?"

Técnicas: optimización, simulación, análisis de decisiones y escenarios.

Ej: ¿cuántas piezas producir mañana? ¿Qué precio maximiza el margen de ganancia?

Clasificación

"¿A qué categoría pertenece?"

Técnicas: regresión logística, árbol de decisión, SVM, redes neuronales.

Ej: ¿Esta pieza es defectuosa o no? ¿Este email es spam? ¿Este paciente se readmitirá?

Glosario de Términos Clave

Árbol de decisión

Algoritmo que usa una estructura de preguntas encadenadas para clasificar datos. Ej: "¿Edad > 70? → rama SÍ: ¿Tomó medicamento? → rama NO: RIESGO ALTO".

Conjunto de entrenamiento (Training set)

Subconjunto de datos históricos con resultados conocidos que se usa para que el modelo "aprenda" los patrones antes de aplicarlo a datos nuevos.

Ingeniería de características (Feature engineering)

Crear nuevas variables a partir de los datos brutos usando conocimiento del dominio. Ej: combinar fecha_ingreso y fecha_egreso para crear "días_hospitalizado".

Estadísticas descriptivas

Media, mediana, mínimo, máximo y desviación estándar. Son el primer análisis que haces para entender qué hay en tu conjunto de datos antes de modelar.

Correlación por pares

Mide la relación entre dos variables. Si dos variables están muy correlacionadas (ej: peso y talla), puedes eliminar una porque no agrega información nueva al modelo.

Modelo descriptivo vs predictivo

Descriptivo: muestra patrones y relaciones (¿qué está pasando?).
Predictivo: genera una probabilidad de resultado futuro (¿qué pasará o qué categoría es?).

Estudio de cohorte

Grupo de individuos con características comunes seguidos en el tiempo. En el caso hospital: todos los pacientes ingresados con diagnóstico primario de insuficiencia cardíaca congestiva.

CRISP-DM

Cross-Industry Standard Process for Data Mining. Metodología de 6 fases ampliamente usada: comprensión del negocio → datos → preparación → modelado → evaluación → despliegue.

Variable / Predictor / Feature

Una columna en tu dataset que describe una característica. Los predictores (features) son las variables que usa el modelo para hacer su predicción o clasificación.

Valores faltantes (missing values)

Datos ausentes o desconocidos. Se manejan con: eliminación del registro, imputación con media/mediana, o marcación como categoría "desconocido" si tiene significado propio.

Retroalimentación en profundidad — Etapa 10

EL MODELO DE "VUELO AL RIESGO" — ¿QUÉ SIGNIFICA?

Flight to Risk Model

¿QUÉ ES?

Un modelo que se "enfoca automáticamente en los pacientes de mayor riesgo", como un avión que vuela directo al peligro. Filtra toda la población y pone en el radar solo a quienes necesitan intervención urgente — sin que nadie tenga que revisar a todos manualmente.

EJEMPLO · HOSPITAL

De 500 pacientes dados de alta esta semana, el modelo identifica automáticamente los 47 con mayor probabilidad de readmisión. El equipo médico se enfoca solo en ellos con seguimiento intensivo, en lugar de intentar atender a todos por igual.

ANALOGÍA

Como un salvavidas con binoculares inteligentes en una playa de 500 bañistas. No vigila a todos igual — los binoculares resaltan automáticamente solo a quienes muestran señales de peligro para actuar antes de que ocurra el accidente.

LOS 3 PASOS DEL PLAN DE RETROALIMENTACIÓN — CASO HOSPITAL

Paso 1

Definir el proceso de revisión

Ejecutivos de manejo clínico se encargan de medir si el modelo realmente reduce readmisiones tras el primer año de implementación.

Paso 2

Seguimiento a pacientes

Se registran los resultados reales de readmisión de cada paciente que recibió intervención. Sin grupo de control por razones éticas — se compara antes vs. después.

Paso 3

Medir y refinar

Se incorporan datos farmacéuticos (antes pospuestos), participación en el programa, y se refinan las acciones del equipo médico con base en la experiencia real.

"Entre más conozcas, más querrás conocer." — John Rollins. La retroalimentación no termina el proceso — lo reinicia con más conocimiento.

CRISP-DM — La metodología estándar de la industria

LAS 6 ETAPAS VS. LAS 10 DE ROLLINS

3 PRINCIPIOS COMPARTIDOS

Iterativo

Puedes volver a cualquier etapa anterior en cualquier momento sin que el proyecto falle.

- | | |
|----------------------------|---|
| 1. Comprensión del negocio | = Etapa 1 de Rollins (idéntica) |
| 2. Comprensión de datos | = Etapas 3 + 4 + 5 de Rollins fusionadas en una |
| 3. Preparación de datos | = Etapa 6 de Rollins (idéntica) |
| 4. Modelado | = Etapa 7 de Rollins (idéntica) |
| 5. Evaluación | = Etapa 8 de Rollins (idéntica) |
| 6. Implementación | = Etapa 9 de Rollins + retroalimentación sin nombre |

Comunicación constante

Con el equipo, la gerencia y los interesados durante todo el proceso — no solo al inicio.

Termina por acuerdo

No cuando el modelo es técnicamente bueno, sino cuando responde las preguntas del negocio.

Data Storytelling — La última milla de los datos

"No importa cuánta información maravillosa hayas presentado. Si no puedes comunicarla a tu audiencia de forma clara y convincente, es para nada." — Profesionales de datos, estudio IBM

LA ESTRUCTURA DE TODA BUENA HISTORIA

1. Contexto — ¿Dónde estamos?

Establece la situación antes de cualquier número. La audiencia necesita saber por qué debería importarle.

Ej: "Llevamos 3 meses con defectos crecientes en la línea 3."

2. Conflicto — ¿Qué está mal?

Los datos son la evidencia del conflicto, no los protagonistas. Sin tensión no hay historia.

Ej: "El 80% de defectos ocurre en las primeras 2 horas del turno nocturno."

3. Resolución — ¿Qué hacemos?

Toda historia con datos debe terminar en una acción concreta. Si no hay acción clara, fallaste.

Ej: "Ajustar la máquina 7 reduciría defectos 60% — son \$2,300 semanales recuperados."

LA TÉCNICA DEL "¿Y QUÉ?"

Cada vez que encuentres un dato, pregúntate 3 veces "¿y qué?" hasta llegar a algo accionable:

"La línea 3 tiene 12% de defectos." → ¿y qué?

"Perdemos 47 piezas por turno." → ¿y qué?

"Son \$2,300 semanales de pérdida." → ¿y qué?

"Intervenimos hoy y lo recuperamos antes de fin de mes."
← Esta es la historia.

Niveles de madurez en storytelling

Nivel 1: Describes lo que ves — "El % subió de 10% a 18%"

Nivel 2: Explicas qué significa — "Son 40 piezas más defectuosas por turno"

Nivel 3: Conectas con el negocio — "\$1,800 de pérdida semanal"

Nivel 4: Propones acción — "Ajustar X reduce eso a 5% en 2 semanas"

Nivel 5: Creas urgencia — "Sin actuar hoy: \$21,000 de pérdida este trimestre"

Recursos para mejorar tu storytelling

Libro: Storytelling with Data — Cole Nussbaumer (estándar de la industria)

Web: The Pudding (pudding.cool) — periodismo de datos con narrativa visual

Blog: Towards Data Science en Medium — análisis bien narrados

Cierre del Curso — La fórmula del éxito

LO QUE APRENDISTE EN EL CURSO

LA FÓRMULA DEL ÉXITO

Del problema al enfoque

Definir el problema de negocio, entender metas y elegir el enfoque analítico correcto.

Trabajar con datos

Requisitos, recolección, comprensión y preparación de datos de forma metódica.

Modelar y evaluar

Construir el modelo con el enfoque adecuado y evaluarlo con métricas reales.

Desplegar y mejorar

Poner el modelo en práctica, obtener retroalimentación y refinarlo continuamente.

Herramientas **correctas**

+ **Momento** **correcto**

+ **Orden** **correcto**

+ **Problema** **correcto**

— John Rollins

Lo que esto significa para ti

No solo sabes que existe el árbol de decisión o la curva ROC — sabes por qué se usan, cuándo se usan y qué pregunta responden. Eso es pensar como científica de datos.